Documentación sobre la herramienta interna - V1

Por Ángel Morales Cirera

La herramienta interna tiene 2 objetivos:

- Documentar los datasets de IBOD de forma centralizada y más o menos estandarizada, conservando una buena flexibilidad.
- Integrar la gestión de la automatización (por ahora no se ha trabajado esto).

Elementos y conexiones

En la herramienta interna se distinguen 5 elementos:

- **Dataset fuente**: un conjunto de datos tal y como se provee.
- **Dataset lógico o transformación**: un conjunto de datos que se deriva de otro u otros datasets, tras realizar algún tipo de acción.
- **Dataset CKAN**: dataset publicado en el CKAN.
- **Visualización**: forma de mostrar unos datos.
- **Producto final**: conjunto de visualizaciones y otros elementos.

La definición de dataset puede tener significados muy diversos. Para esta herramienta no se entiende un dataset como un archivo, ya que un dataset puede tener diversos archivos en momentos diferentes. Por lo tanto, hay que ir a un nivel más abstracto, y esa abstracción genera ambigüedades.

¿Qué es un dataset fuente?

Un dataset fuente es un dataset que no se deriva de una acción que hacemos nosotros sobre otro dataset. Serán los datasets que descarguemos (en la inmensa mayoría de ocasiones), o que generemos a partir de nuestras herramientas (por ejemplo registros o, en un ámbito más industrial, podrían ser sensores).

Como particularidad, a un dataset fuente le asociamos una fuente, un propietario y una URL.

¿Qué es un dataset lógico?

Es un conjunto de datos que se deriva de otro tras *realizar algo*. Por ejemplo, acciones como *descargar*, *filtrar*, *agregar*… dan lugar a subsets distintos, y necesitan un origen.

¿Qué es un dataset CKAN?

En CKAN, un dataset se forma de unos metadatos junto con varios archivos. Los archivos pueden haberse conseguido aplicando transformaciones diferentes sobre fuentes diferentes, lo que implica que un dataset CKAN es distinto a los otros datasets: se puede formar de varios de ellos.

Un dataset CKAN tiene un papel *intermedio* entre datasets lógicos.

¿Y los archivos?

Un archivo tiene sus propios metadatos, como la fecha de subida. Todo archivo se asocia exactamente a un elemento, pero un elemento puede tener varios archivos (por ejemplo de sus distintas versiones, o en distintos formatos).

Las conexiones entre elementos

Todo elemento puede tener un número indefinido de descendientes para todos los casos descritos ("si puedo sacarle uno de estos, le puedo sacar dos").

Hay ciertas conexiones que muestran un significado claro y son las preferibles:

- Flujo sin CKAN:
  - **1 dataset fuente -> dataset lógico**: significa *descargar* los datos de la fuente, con la posibilidad de aplicar filtros directamente aquí, o de usar una API.
  - **Uno o varios dataset(s) lógico(s) -> dataset lógico**: significa *transformar* datos de alguna forma (por ejemplo filtrar columnas, agregar, cruzar varios datasets…)
  - **1 dataset lógico -> visualización**: significa *mostrar* los datos de alguna forma gráfica.
  - **Varias visualizaciones o datasets-> producto final**

- Intervención del CKAN:
  - **Uno o varios dataset(s) lógico(s) -> dataset CKAN**: significa subir un archivo de este dataset lógico al CKAN. Los datasets lógicos pueden tener muy poco que ver.
  - **1 dataset CKAN -> dataset lógico**: significa volver a descargar los datos desde el CKAN, quizás aplicando algún filtro o agregación.

Hay ciertas conexiones que no tienen sentido, y se han prohibido para evitar errores en el programa:

- *** -> dataset fuente**: nada puede derivar en un dataset fuente.
- **Producto final -> ***: el producto final no se puede usar en otro sitio.
- **Visualización -> dataset o visualización**: una visualización solo sirve para hacer productos finales.
  - Si bien es cierto que hay visualizaciones que son "conjuntos" de otras, siempre será una mera secuencia. Se ha prohibido este caso para simplificar el programa.

Hay ciertos casos ambiguos. Estos se permiten en el programa, pero reducen ligeramente su potencial, ya que no se han programado.

- **Más de un dataset fuente -> dataset lógico**: normalmente se harán pasos por separado en cada fuente, lo que implica usar datasets lógicos intermedios.
- **Dataset fuente -> visualización o dataset CKAN**: normalmente siempre se debe hacer algo con la fuente, aunque sea tan sencillo como aplicar una API. Es preferible usar un dataset lógico intermedio.
    - Si no se usa el dataset lógico entre la fuente y la visualización, la vista tabular del producto no muestra los metadatos del dataset, ya que ignora datasets fuente.
- **Múltiples datasets -> visualización o dataset CKAN**: normalmente se deben juntar los datos realizando algo sobre ellos antes de generar la visualización, lo que implica un dataset lógico intermedio.
    - Si no se usa el dataset lógico intermedio antes de la visualización, la vista tabular del producto no muestra los metadatos de ningún dataset, ya que no muestra múltiples datasets para una sola visualización.
    - Los metadatos de una visualización no definen el dataset usado (por ejemplo las variables o desagregaciones) porque esta información se espera que esté en el dataset lógico conectado a la visualización.

Otros consejos y casos

- Si queremos mostrar unos datos de varias formas, tenemos múltiples opciones:
    - Usar una visualización y añadirle varios archivos: aconsejable si solo cambia el formato (por ejemplo los colores).
    - Usar múltiples visualizaciones: aconsejable si las visualizaciones son de diferente tipo (por ejemplo gráfico de barras vs mapa).

- La existencia de los elementos es, a nivel técnico, independiente del resto.
    - Se puede documentar un dataset lógico aunque no se derive de ningún otro dataset lógico, fuente ni CKAN.
    - Se puede documentar una visualización sin dataset (aunque lo recomendable es ponerle uno lógico).
    - Se puede documentar un dataset CKAN suelto.
    - …

- Los comentarios internos tienen muchas utilidades. Por ejemplo, una visualización puede haberse actualizado, pero no colocado, en el producto final. Esto se puede dejar comentado y marcar el producto como “desactualizado”, manteniendo la visualización como “actualizada”.

Metadatos

Los metadatos de los elementos se guardan en un listado de metadatos estándar. Cada metadato se forma por una clave y un valor. El usuario puede modificar esta lista haciendo clic en "⚙️ Metadatos estándar".

La **lista de metadatos estándar** permite:

- Al documentar un nuevo elemento, tener la lista de claves ya colocada y lista para rellenar. Se marcan en gris los vacíos, y en verde los rellenos.
- Vincular metadatos entre elementos. Luego se entra en detalle.
- Al acceder a la vista tabular del producto, las columnas de la lista estándar tienen preferencia.

A pesar de tener esta lista, se permite añadir metadatos de forma independiente para cualquier elemento. Estos se marcarán en rojo.

Cambiar la lista no borra los metadatos existentes de ningún elemento, pero si se han eliminado las claves, se pasan a marcar en rojo. A futuro, se puede añadir una función para actualizar una clave (nombre del metadato) en todos elementos.

Vincular metadatos (pendiente de implementación)

Como se ha podido observar, los datasets lógicos abundan entre las diferentes piezas. Para hacer fácil su documentación, se podrán linkear o vincular los metadatos para que un dataset lógico los "coja" de alguno de sus antecesores directos, siempre que este sea un dataset lógico o fuente (no CKAN, ya que los metadatos de CKAN son distintos).

Vincular un metadato implica que:

- No se podrá cambiar desde este elemento (a no ser que se desvincule). Se debe modificar en el antecesor.
- Un cambio en el antecesor se refleja en este elemento.

Vistas

El programa permite visualizar los elementos de diversas formas:

- **Grafo**: 4 columnas con elementos.
- **Catálogo**: lista de todos los elementos.
- **Tabla de producto**: formato parecido al Excel que se usaba hasta ahora.

Se pueden seleccionar productos finales y elementos. La selección de producto final afecta a las vistas de grafo y catálogo, cambiando los elementos visibles.

Un menú lateral acompaña todas las pestañas para tener los detalles del elemento seleccionado.

Particularidades:

- El grafo y la tabla de producto permiten modificar la mayoría de los metadatos.

- Grafo
    - Es la vista más compleja y completa, es la principal.
    - Es la única vista que permite añadir relaciones entre elementos.
    - Al seleccionar un producto final, ignora los elementos que solo estén relacionados con otros proyectos (por lo tanto solo resalta los que están relacionados consigo mismo o con ningún proyecto).

- Catálogo
    - Permite tener una lista de los archivos.

- Tabla de producto
    - Cada fila es una visualización o un dataset lógico conectado al producto.
        - Si hay un flujo 1 dataset lógico -> 1 visualización, aparecen en la misma fila ambos elementos.

Otros aspectos

Hay 3 posibles métodos de actualización: manual, semiautomático y automático. Todo dataset documentado manualmente tiene el tipo “manual”. El usuario no puede cambiarlo.

Hay 4 posibles estados: actualizado, desactualizado, permanente y provisional.

- Si se cambia un elemento de “actualizado” a “desactualizado”, el cambio se propaga a todos los descendientes (pendiente de implementar).